

Categorización de Tumores

José Juan Hernández Gálvez¹

¹*jose.hernandez219@alu.ulpgc.es*

Resumen

En el presente informe, se aborda el desafío de la categorización de imágenes de tumores cerebrales: glioma, meningioma y pituitario, utilizando redes neuronales. Dada la naturaleza compleja y variada de las imágenes de tumores cerebrales, es esencial adoptar técnicas avanzadas de procesamiento de imágenes y aprendizaje automático para una clasificación precisa. Se describen los detalles sobre la preparación de los datos, la arquitectura de la red neuronal utilizada y el proceso de entrenamiento. Los resultados preliminares indican que las redes neuronales muestran un gran potencial en la identificación y clasificación de diferentes tipos de tumores cerebrales con una alta precisión.

1. Introducción

El cerebro es un órgano vital cuyas afecciones requieren diagnósticos precisos y tempranos. Los tumores cerebrales, tales como el glioma, meningioma y pituitario, son cánceres que, de no ser detectados y tratados a tiempo, pueden tener consecuencias devastadoras para el paciente. Tradicionalmente, el diagnóstico y la categorización de estos tumores se basan en técnicas de imagenología y la interpretación de especialistas. Sin embargo, con el vasto número de imágenes a analizar y la sutil variabilidad entre los diferentes tipos de tumores, el margen de error humano puede ser una preocupación.

El rápido desarrollo del machine learning y el deep learning en los últimos años, ha abierto una nueva ventana de investigación para revolucionar el diagnóstico médico. Las redes neuronales, en particular, han mostrado ser herramientas poderosas en la categorización y el análisis de imágenes médicas, ofreciendo diversas ventajas en comparación con los métodos convencionales.

En este informe, exploraremos en detalle cómo las redes neuronales se aplican a la tarea de categorizar imágenes de tumores cerebrales.

2. Datalake

En el mundo actual de datos masivos y crecientes, la gestión y organización de la información se ha vuelto esencial para garantizar la eficiencia y la precisión en cualquier campo, y más aún en el ámbito médico. La creación y uso de un Datalake, un repositorio centralizado que permite almacenar grandes cantidades de datos en su formato natural, es un paso clave en la preparación para investigaciones de alto impacto, como es el caso de la categorización de imágenes de tumores cerebrales mediante redes neuronales. La habilidad de un Datalake para gestionar información no estructurada es particularmente crucial en el ámbito del desarrollo de redes neuronales, donde es imperativo llevar a cabo un análisis detallado y profundo de los datos.

- **Centralización de los datos:** Tener un único punto de acceso a todos los datos garantiza que los investigadores y especialistas tengan a su disposición toda la información necesaria de forma rápida y sencilla. Esta centralización minimiza el riesgo de duplicidades, inconsistencias y pérdida de información.
- **Escalabilidad y Flexibilidad:** A medida que la investigación avanza y se generan más datos, un Datalake es inherentemente escalable. Si en el futuro se desea incorporar más imágenes o cualquier otro tipo de dato, el proceso es fluido. Los Datalakes están diseñados para adaptarse y crecer con las necesidades del proyecto.

- **Integración de Metadata:** Al añadir un nuevo conjunto de datos o *evento*, se incluye su metadata asociado. Esto es crucial para garantizar que los datos se pueden localizar, entender y utilizar correctamente. Esta metadata puede incluir detalles sobre el origen de la imagen, el tipo de dato, la marca de tiempo, entre otros.
- **Creación de Datamarts:** Un beneficio adicional de utilizar un Datalake es la capacidad de crear Datamarts. Estos son vistas del datalake y se estructuran de una manera específica para un propósito particular, como podría ser el entrenamiento de una red neuronal. Esto permite a los investigadores adaptar y moldear los datos según las necesidades específicas de cada estudio o análisis, sin afectar la integridad o estructura del Datalake original.

En conclusión, la implementación de un Datalake no es solo una inversión en la investigación actual, sino una preparación para el futuro, asegurando que se tenga una infraestructura sólida y flexible que pueda adaptarse y responder a las demandas del mundo en constante cambio de la ciencia de datos y la medicina. Con esta base, podemos proceder a explorar el potencial de las redes neuronales en el diagnóstico y categorización de imágenes de tumores cerebrales.

3. Información del Dataset de Tumores Cerebrales

El dataset de tumores cerebrales se compone de imágenes de resonancia magnética (MRI) de cerebros, clasificadas en tres categorías principales de tumores:

- Glioma
- Meningioma
- Tumor pituitario

3.1. Datos de Entrenamiento

En el conjunto de entrenamiento, se cuenta con las siguientes cantidades de imágenes por categoría:

- Glioma: 1,283 imágenes de tamaño promedio 512x512 píxeles.
- Meningioma: 637 imágenes de tamaño promedio 512x512 píxeles.
- Tumor pituitario: 837 imágenes de un tamaño promedio aproximado de 508x508 píxeles.

3.2. Datos de Prueba

El conjunto de prueba contiene:

- Glioma: 143 imágenes de tamaño promedio 512x512 píxeles.
- Meningioma: 71 imágenes de tamaño promedio 512x512 píxeles.
- Tumor pituitario: 93 imágenes de un tamaño promedio aproximado de 506x506 píxeles.

Este dataset proporciona una variedad significativa de casos para entrenar y validar modelos de clasificación de imágenes médicas centrados en la identificación y diferenciación de tumores cerebrales.

4. Preprocesamiento de las Imágenes

Para estandarizar el dataset y facilitar el análisis posterior, todas las imágenes del dataset de tumores cerebrales se sometieron a un proceso de preprocesamiento. Este proceso tuvo como objetivo principal adaptar el tamaño de cada imagen a un formato estándar, garantizando así que todas las imágenes tengan las mismas dimensiones.

4.1. Redimensionamiento (Resize)

El único paso de preprocesamiento realizado fue redimensionar cada imagen a un tamaño de 100×100 píxeles. El redimensionamiento es crucial para:

- Asegurar que cada imagen tenga el mismo tamaño, lo cual es esencial para la mayoría de los algoritmos de aprendizaje automático y aprendizaje profundo.
- Reducir la cantidad de información y, por lo tanto, el costo computacional al entrenar modelos, especialmente en datasets grandes.
- Mantener un nivel de detalle suficiente en las imágenes, permitiendo la identificación y clasificación de características relevantes, mientras se descartan detalles innecesarios o redundantes.

Es importante notar que, al cambiar el tamaño de las imágenes, se puede perder información. Sin embargo, en muchos casos, el nivel de detalle mantenido en 100×100 píxeles es suficiente para tareas de clasificación y análisis en el ámbito médico.

5. Redes Neuronales

Las redes neuronales han evolucionado significativamente en las últimas décadas, diversificando sus estructuras para adaptarse a diferentes tipos de datos y problemas. En el contexto de la clasificación de imágenes, se han desarrollado múltiples arquitecturas que buscan maximizar la precisión y eficiencia en la detección y categorización de patrones en imágenes. En esta sección, exploraremos en detalle las arquitecturas de redes neuronales seleccionadas para este estudio: FC (Fully Connected), CNN1, CNN2, CNN3 y ResNet18. Cada una de estas redes presenta características y enfoques distintivos, lo que las hace adecuadas para diferentes aspectos del análisis de imágenes de tumores cerebrales.

5.1. FC (Fully Connected)

Las redes Fully Connected, también conocidas como redes neuronales densamente conectadas, son una de las estructuras básicas en el mundo de las redes neuronales. Todos los nodos en una capa están conectados a todos los nodos en la capa siguiente, lo que les permite capturar relaciones en los datos. Sin embargo, debido a su naturaleza, suelen tener un gran número de parámetros.

5.1.1. Parámetros de entrenamiento

Se experimentó con cuatro diferentes optimizadores: Adam, Adagrad, SGD y Adadelta. Asimismo, se evaluaron dos funciones de pérdida: MSE (Error Cuadrático Medio) y CrossEntropyLoss. Tras realizar pruebas exhaustivas, se determinó que, independientemente del valor del learning rate, la combinación que ofrecía los mejores resultados era el optimizador Adam junto con la función de pérdida MSE.

Las siguientes gráficas muestran el comportamiento del modelo en términos de precisión (accuracy) y pérdida (loss) a lo largo de los epochs de entrenamiento para esta particular combinación.

5.1.2. Evolución de la Precisión (Accuracy)

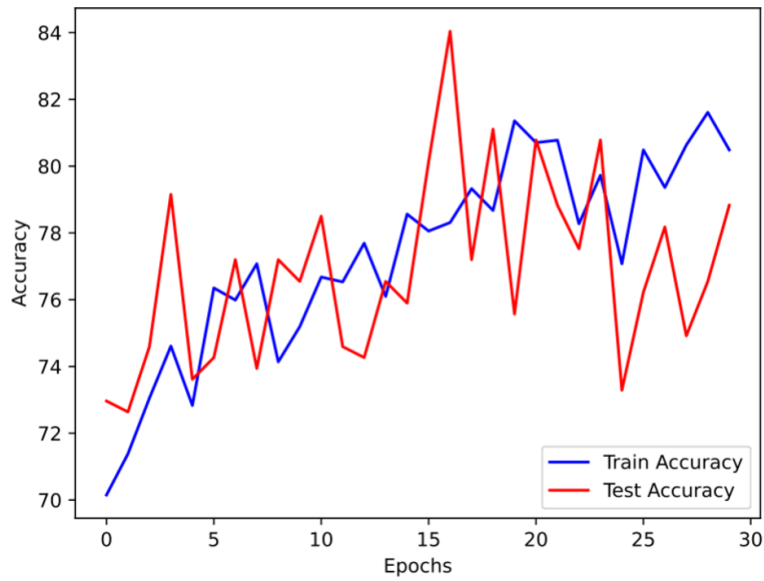


Figura 1: Evolución de la precisión de entrenamiento y prueba a lo largo de las épocas.

En la Figura 9, se observa cómo varía la precisión de entrenamiento (Train Accuracy) y prueba (Test Accuracy) con el paso de las épocas. Es destacable que la precisión en el conjunto de prueba alcanza un valor de 84%, lo que indica un buen rendimiento de la red en datos no vistos durante el entrenamiento.

5.1.3. Evolución de la Pérdida (Loss)




Figura 2: Evolución de la pérdida de entrenamiento a lo largo de las épocas.

La Figura 11 muestra la pérdida de entrenamiento durante las épocas. Aunque presenta fluctuaciones, es un comportamiento esperado en muchos escenarios de entrenamiento, especialmente cuando se utilizan optimizadores adaptativos o tasas de aprendizaje variables.

5.1.4. Conclusiones

A pesar de las fluctuaciones en la pérdida de entrenamiento, los resultados no pueden considerarse desfavorables. De hecho, lograr una precisión del 84% en el conjunto de prueba es un indicativo de que la red ha

aprendido características relevantes de los datos y es capaz de generalizar bien en datos no vistos. Sin embargo, debido a su naturaleza lineal, la red tiene limitaciones inherentes que podrían impedirle alcanzar resultados aún mejores.

5.2. ConvNet1

- **Bloques Convolucionales:** Esta red cuenta con dos bloques convolucionales. Cada bloque incluye una capa convolucional seguida de una función de activación ReLU y una capa de pooling.
- **Entrada y Salida:** La primera capa convolucional toma una imagen con 3 canales (típicamente RGB) y produce 32 características, mientras que la segunda convolucional transforma estas 32 características en 64.
- **Capa Linear:** Tras los bloques convolucionales, la red aplanla la salida y la pasa a través de una capa lineal que reduce la dimensión a 3, que probablemente corresponde al número de clases de tumores cerebrales.

5.2.1. Parámetros de entrenamiento

Se experimentó con cuatro diferentes optimizadores: Adam, Adagrad, SGD y Adadelta. Asimismo, se evaluaron dos funciones de pérdida: MSE (Error Cuadrático Medio) y CrossEntropyLoss. Tras realizar pruebas exhaustivas, se determinó que, independientemente del valor del learning rate, la combinación que ofrecía los mejores resultados era el optimizador Adam junto con la función de pérdida MSE.

Las siguientes gráficas muestran el comportamiento del modelo en términos de precisión (accuracy) y pérdida (loss) a lo largo de los epochs de entrenamiento para esta particular combinación.

5.2.2. Evolución de la Precisión (Accuracy)

La Figura 9 muestra la precisión del modelo en el conjunto de entrenamiento y prueba a lo largo de las épocas.




Figura 3: Precisión de entrenamiento y prueba a lo largo de las épocas para CNN1.

Como se puede observar, el modelo logra una precisión del 90.9% en el conjunto de prueba, lo cual es indicativo de que ha aprendido características relevantes y es capaz de generalizar bien en datos no vistos.

5.2.3. Evolución de la Pérdida (Loss)




Figura 4: Pérdida de entrenamiento a lo largo de las épocas para CNN1.

La primera gráfica muestra la pérdida durante el entrenamiento. Se puede observar que la pérdida tiene altos y bajos, pero tiende a disminuir a medida que avanzan las épocas. Es un comportamiento esperado en un entrenamiento.

5.2.4. Conclusión

Los resultados obtenidos por la CNN1 son prometedores, logrando una precisión del 90.9 % en el conjunto de prueba. Esto sugiere que el modelo ha aprendido patrones relevantes de los datos y tiene un buen rendimiento en datos no vistos. No obstante, siempre hay margen de mejora y optimización en la arquitectura y parámetros del modelo.

5.3. ConvNet2

- **Bloques Convolucionales con Normalización:** Al igual que la ConvNet1, esta red utiliza dos bloques convolucionales. Sin embargo, añade una capa de normalización por lotes (BatchNorm) antes de la función de activación ReLU.
- **Entrada y Salida:** El flujo de entrada y salida en las capas convolucionales es el mismo que en ConvNet1, de 3 canales a 32 características y luego a 64 características.
- **Capa Linear con Dropout:** La capa lineal en este caso viene precedida por una capa de Dropout con una tasa del 50 %, que tiene como objetivo reducir el sobreajuste al entrenar la red.

5.3.1. Parámetros de entrenamiento

Se experimentó con cuatro diferentes optimizadores: Adam, Adagrad, SGD y Adadelta. Asimismo, se evaluaron dos funciones de pérdida: MSE (Error Cuadrático Medio) y CrossEntropyLoss. Tras realizar pruebas exhaustivas, se determinó que, independientemente del valor del learning rate, la combinación que ofrecía los mejores resultados era el optimizador Adam junto con la función de pérdida MSE.

Las siguientes gráficas muestran el comportamiento del modelo en términos de precisión (accuracy) y pérdida (loss) a lo largo de los epochs de entrenamiento para esta particular combinación.

5.3.2. Evolución de la Precisión (Accuracy)




Figura 5: Precisión en los conjuntos de entrenamiento y prueba

En la primera gráfica, se representan las métricas de precisión (accuracy) tanto para el conjunto de entrenamiento (en azul) como para el de prueba (en rojo). Es alentador observar que ambas métricas siguen tendencias similares y no muestran signos claros de sobreajuste, ya que no hay una gran divergencia entre ellas. Específicamente, la precisión en el conjunto de prueba alcanza un valor del 91.9%, lo cual es un indicativo de que el modelo tiene un buen rendimiento.

5.3.3. Evolución de la Pérdida (Loss)




Figura 6: Gráfica de pérdida durante el entrenamiento

La segunda gráfica muestra la pérdida durante el entrenamiento. Se puede observar que la pérdida tiene altos y bajos, pero tiende a disminuir a medida que avanzan las épocas. Es un comportamiento esperado en un entrenamiento.

5.3.4. Conclusión

El análisis de estas métricas muestra que el modelo tiene un rendimiento sólido. La pérdida disminuye con el tiempo, y la precisión en el conjunto de pruebas es alta. Estos factores, combinados con la ausencia de signos

claros de sobreajuste, sugieren que el modelo está bien ajustado y es probable que generalice bien en datos no vistos.

5.4. ConvNet3

- **Bloques Convolucionales con Normalización:** ConvNet3 amplía la estructura incorporando un tercer bloque convolucional con normalización por lotes.
- **Entrada y Salida:** La red comienza tomando una imagen con 3 canales, la convierte a 32 características en el primer bloque, a 64 en el segundo bloque y finalmente a 128 características en el tercer bloque.
- **Capa Linear:** Similar a ConvNet1, después de procesar la imagen a través de los bloques convolucionales, la salida se aplanan y se pasa a través de una capa lineal para obtener una salida de dimensión 3.

5.4.1. Parámetros de entrenamiento

Se experimentó con cuatro diferentes optimizadores: Adam, Adagrad, SGD y Adadelta. Asimismo, se evaluaron dos funciones de pérdida: MSE (Error Cuadrático Medio) y CrossEntropyLoss. Tras realizar pruebas exhaustivas, se determinó que, independientemente del valor del learning rate, la combinación que ofrecía los mejores resultados era el optimizador Adam junto con la función de pérdida MSE.

Las siguientes gráficas muestran el comportamiento del modelo en términos de precisión (accuracy) y pérdida (loss) a lo largo de los epochs de entrenamiento para esta particular combinación.

5.4.2. Evolución de la Precisión (Accuracy)




Figura 7: Precisión de entrenamiento y prueba a lo largo de los epochs para el modelo CNN3.

La Figura 9 ilustra la precisión del modelo durante el proceso de entrenamiento (en azul) y prueba (en rojo). Se observa que el modelo alcanza una precisión de prueba de 94.5 %, lo cual es un resultado muy sobresaliente.

5.4.3. Evolución de la Pérdida (Loss)




Figura 8: Pérdida de entrenamiento a lo largo de los epochs para el modelo CNN3.

En la Figura 11, se muestra la evolución de la pérdida durante el entrenamiento. A pesar de algunas fluctuaciones, se aprecia una tendencia decreciente, lo cual indica que el modelo está aprendiendo y adaptándose a los datos.

5.4.4. Conclusión

El modelo CNN3 ha demostrado ser efectivo, alcanzando una precisión en el conjunto de prueba de 94.5 %. Las gráficas de precisión y pérdida reflejan un comportamiento esperado durante el proceso de entrenamiento. La alta precisión obtenida en el conjunto de prueba sugiere que el modelo es capaz de generalizar bien a nuevos datos, lo cual es esencial en aplicaciones prácticas.

5.5. ResNet18

ResNet18 pertenece a la familia de las Residual Networks. Esta arquitectura introduce el concepto de conexiones residuales, permitiendo a la red aprender funciones residuales en lugar de aprender directamente la función deseada. Esto ayuda a combatir el problema de la desaparición del gradiente en redes muy profundas, y ha demostrado ser eficaz en la clasificación de imágenes con alta precisión.

5.5.1. Parámetros de entrenamiento

Se experimentó con cuatro diferentes optimizadores: Adam, Adagrad, SGD y Adadelta. Asimismo, se evaluaron dos funciones de pérdida: MSE (Error Cuadrático Medio) y CrossEntropyLoss. Tras realizar pruebas exhaustivas, se determinó que, independientemente del valor del learning rate, la combinación que ofrecía los mejores resultados era el optimizador Adam junto con la función de pérdida MSE.

Las siguientes gráficas muestran el comportamiento del modelo en términos de precisión (accuracy) y pérdida (loss) a lo largo de los epochs de entrenamiento para esta particular combinación.

5.5.2. Precisión (Accuracy)




Figura 9: Evolución de la precisión durante el entrenamiento.

Como se puede observar en la Figura 9, la precisión de entrenamiento (en azul) incrementa progresivamente durante las primeras épocas, estabilizándose alrededor del 98 %. Por otro lado, la precisión de prueba (en rojo) muestra una tendencia similar, alcanzando un valor máximo de 95.4 %.

5.5.3. Pérdida (Loss)




Figura 10: Evolución de la pérdida durante el entrenamiento.

La Figura 11 muestra la evolución de la pérdida durante el entrenamiento. Se puede observar que la pérdida disminuye rápidamente durante las primeras épocas y luego se estabiliza, con ciertos picos que pueden indicar momentos en los que el modelo ajusta sus parámetros.

5.5.4. Conclusión

El modelo ResNet18 ha demostrado un rendimiento impresionante durante su fase de entrenamiento, logrando una precisión de prueba del 95.4 %. Esto indica que el modelo es capaz de generalizar bien a nuevos datos, convirtiéndolo en el mejor modelo entrenado hasta el momento. Es importante continuar monitoreando su rendimiento en escenarios del mundo real y considerar la posibilidad de realizar ajustes finos si es necesario.

6. Conclusión

En el ámbito de las redes neuronales, la elección de la arquitectura es fundamental para obtener buenos resultados. Como se observa en la gráfica, aunque todos los modelos presentados tienen un rendimiento elevado, el modelo resnet18 se destaca por su alta precisión, confirmando su robustez y capacidad para manejar el conjunto de datos en cuestión. Es esencial considerar tanto la precisión de entrenamiento como la de prueba al evaluar la eficacia de un modelo, y en este caso, resnet18 ha demostrado ser el modelo más eficaz entre los evaluados.




Figura 11: Rendimiento de cada modelo.

7. Trabajo a Futuro

A medida que avanzamos en el entendimiento y desarrollo de redes neuronales para el diagnóstico médico basado en imágenes, es imperativo considerar futuras direcciones y ampliaciones de este trabajo.

- **Expansión de Datasets:** La inclusión de más imágenes y, potencialmente, de otras modalidades de imágenes médicas podría mejorar aún más la precisión y robustez de los modelos de redes neuronales.
- **Incorporación de Técnicas Avanzadas:** La implementación de técnicas más avanzadas en procesamiento de imágenes y aprendizaje profundo, como transfer learning o fine tuning, podría impulsar las capacidades de nuestros modelos actuales.